ЛАБОРАТОРНАЯ РАБОТА №1

EDA, ТИПЫ ДАННЫХ И СВОДКА

ЦЕЛЬ РАБОТЫ

Научиться:

1. Определять типы данных в реальной таблице.
2. Находить «грязные» данные и «красные флаги» в массиве контрагентов.
3. Делать первичную сводку с помощью функций Excel и сводной таблицы.
4. Строить распределение частот и полигон частот.
5. Формулировать вывод для службы безопасности.

ИСХОДНЫЕ ДАННЫЕ

Файл-заготовка: `lab1_contractors.xlsx`
Лист: «Вариант *»
Количество записей: 100 строк
Признаки:

Столбец	Признак	Пример
A	Номер	1
B	Наименование	ООО «Ромашка»
C	ИНН	7701234567
D	Дата регистрации	15.03.2015
E	Уставной капитал, руб.	10 000
F	Выручка за год, руб.	45 000 000
G	Среднесписочная численность	12
H	Телефон	+7 (495) 123-45-67

Столбец	Признак	Пример
I	Адрес	г. Москва, ул. Ленина, д. 1
J	Форма собственности	ООО / АО / ИП

Важно: файл намеренно содержит ошибки, пропуски, дубликаты и выбросы. Их нужно найти. Это учебные данные, а не реальная отчётность.

ТЕОРЕТИЧЕСКИЙ МИНИМУМ

1. Типы данных

Любое статистическое исследование в первую очередь работает с данными (показателями или признаками того или иного исследуемого объекта). Прежде чем считать, нужно понять, с чем работаем.

Количественные — выражаются числом.

- **Непрерывные** — могут принимать любое значение на шкале: выручка, уставной капитал, сумма сделки.
- **Дискретные** — конечный набор значений: численность сотрудников, количество филиалов.

Качественные (номинальные) — нельзя выразить числом: форма собственности, регион, вид деятельности.

Порядковые (ранговые) — можно упорядочить, но нельзя измерить расстояние: уровень риска («низкий / средний / высокий»), рейтинг контрагента.

Зачем это нужно. От типа данных зависит, какие методы применимы. Для номинальных, к примеру нельзя считать среднее, для порядковых лучше работают ранговые коэффициенты, и т.д.

2. Распределение частот

Каждая совокупность характеризуется **распределением** значений признака.

- **Частота** — сколько раз встретилось значение.

- **Относительная частота** — доля: f = M / N, где M — число единиц с данным значением, N — объём совокупности.
- Сумма всех относительных частот равна 1 (или 100%, если выражена в %).

Полигон частот — столбчатая диаграмма, где по оси X — значения признака, по оси Y — частота. Огибающая линия — график распределения.

Зачем это нужно. Распределение показывает, как устроена совокупность: где основная масса, есть ли «горбы», симметрично ли расположены значения. Для службы безопасности это первый способ увидеть неоднородность.

3. «Красные флаги» в данных

Тип аномалии	Пример	Что означает
Пропуск	Пустой телефон	Потеря контакта, неполные реквизиты
Ошибочное значение	ИНН из 5 цифр	Ошибка ввода
Нелогичное сочетание	Выручка 500 млн при штате 1 человек	Признак фирмы-однодневки
Дубликат	Один ИНН дважды	Возможна попытка задвоить контрагента
Выброс	Уставной капитал 10 руб. или 10 млрд руб.	Ошибка ввода данных, влияет на статистику

ХОД РАБОТЫ

Задание 1.1. Типы данных и «грязные» данные

Шаг 1. Откройте файл `lab1_contractors.xlsx`. Найдите данные своего варианта. Можете скопировать их в новый файл, либо работать в этом же, удалив лишние листы с вариантами.

Шаг 2. Создайте новый лист и назовите его «Типы данных». В столбец A выпишите названия всех признаков (Наименование, ИНН, Дата регистрации, Уставной капитал, Выручка, Численность, Телефон, Адрес, Форма собственности). В столбец B — тип данных: «количественный непрерывный», «количественный дискретный», «качественный», «порядковый».

Шаг 3. Вернитесь на лист «Контрагенты». Проверьте данные на аномалии. Используйте следующие инструменты.

Поиск пропусков: автоматическое выделение (Условное форматирование)

1. Выделите диапазон ячеек, в котором нужно найти и закрасить пустые места.
2. На вкладке «Главная» нажмите кнопку «Условное форматирование» → «Создать правило».
3. В появившемся окне выберите тип правила: «Использовать формулу для определения форматируемых ячеек».
4. В поле для формулы введите функцию:
   =ЕПУСТО(A1, где A1 — это первая ячейка вашего выделенного диапазона.
5. Нажмите кнопку «Формат», перейдите на вкладку «Заливка» и выберите нужный цвет.
6. Нажмите ОК, а затем еще раз ОК для сохранения правила.

Поиск ошибочных значений.

1. Выделите столбец B (ИНН).
2. На вкладке «Данные» нажмите «Фильтр» (или `Ctrl+Shift+L`).
3. Нажмите на стрелку в заголовке столбца → «Числовые фильтры» → «Настраиваемый фильтр».
4. В первом поле выберите «меньше», во втором введите «10» (ИНН должен быть 10 или 12 цифр). Нажмите «ОК».
5. Excel покажет строки с подозрительно короткими ИНН. Запишите их номера и значения или выделите цветом.

Поиск нелогичных сочетаний.

1. Выделите столбцы E (Выручка) и F (Численность).
2. Примените фильтр к столбцу E: «Числовые фильтры» → «Больше» → введите «100000000» (100 млн).
3. Среди отфильтрованных строк найдите те, где численность = 1 или 2. Это потенциальные фирмы-однодневки. Выделите их.

Поиск дубликатов.

1. Выделите столбец B (ИНН).
2. На вкладке «Главная» нажмите «Условное форматирование» → «Правила выделения ячеек» → «Повторяющиеся значения».
3. Нажмите «ОК». Дубликаты будут выделены. Запишите, какой ИНН повторяется и в каких строках.

Поиск выбросов.

1. Выделите столбец D (Уставной капитал).
2. На вкладке «Данные» нажмите «Сортировка» → «По возрастанию». Подтвердите пункт «автоматически расширить диапазон».
3. Посмотрите на минимальные и максимальные значения. Если есть 10 руб. или 10 млрд руб. — это выбросы. Отметьте их.
4. Верните сортировку по исходному порядку (или используйте нумерацию строк, если она есть).

Шаг 4. Создайте новый лист «Аномалии». Оформите таблицу:

№	Тип аномалии	Контрагент	Значение	Комментарий
1	Пропуск	ИП Петров П.П.	Телефон пуст	Потеря контакта
2	Ошибочное значение	ООО «Бета»	ИНН 12345	Короче 10 цифр
3	Нелогичное сочетание	ООО «Дельта»	Выручка 500 млн, штат 1	Признак однодневки
4	Дубликат	ООО «Эпсилон»	ИНН 7701234567	Повтор
5	Выброс	ООО «Дзета»	Уставной капитал 10 руб.	Аномалия

Требование: найти не менее 5 типов аномалий. Чем больше — тем лучше.

Задание 1.2. Первичная сводка

Шаг 1. Создайте новый лист «Сводка».

Шаг 2. В столбец A выпишите показатели, в столбец B — формулы.

Показатель	Формула	Ячейка
Общее количество контрагентов	`=СЧЁТЗ(Контрагенты!A2:A101)`	B2

Показатель	Формула	Ячейка
Количество с пропусками в поле телефон	`=СЧИТАТЬПУСТОТЫ(Контрагенты!G2:G101)`	B3
Количество с выручкой > 100 млн	`=СЧЁТЕСЛИ(Контрагенты!E2:E101;">100000000")`	B4
Количество с численностью 1 человек	`=СЧЁТЕСЛИ(Контрагенты!F2:F101;1)`	B5
Средняя выручка	`=СРЗНАЧ(Контрагенты!E2:E101)`	B6
Минимальная выручка	`=МИН(Контрагенты!E2:E101)`	B7
Максимальная выручка	`=МАКС(Контрагенты!E2:E101)`	B8

Пояснение по функциям:

- `СЧЁТЗ` — считает непустые ячейки.
- `СЧИТАТЬПУСТОТЫ` — считает пустые ячейки в диапазоне.
- `СЧЁТЕСЛИ` — считает ячейки по условию.
- `СРЗНАЧ`, `МИН`, `МАКС` — среднее, минимум, максимум.

Шаг 3. Проверьте, что все формулы возвращают числа. Если где-то ошибка — проверьте диапазон и разделители (в русской версии Excel разделитель — точка с запятой).

Шаг 4. Дополнительно постройте сводную таблицу:

1. Выделите диапазон A1:I101 на листе «Контрагенты».
2. Вкладка «Вставка» → «Сводная таблица».
3. В диалоговом окне выберите «На новый лист», нажмите «ОК».
4. В области «Поля сводной таблицы» перетащите:
   - «Форма собственности» в область «Строки»;
   - «Наименование» в область «Значения» (Excel посчитает количество).
5. Получите таблицу: сколько ООО, АО, ИП.

Результат: сводная таблица с 7 показателями + сводная таблица по формам собственности.

Задание 1.3. Распределение частот и полигон

Шаг 1. Создайте новый лист «Частоты».

Шаг 2. Постройте таблицу частот по форме собственности.

Форма собственности	Частота	Относительная частота	Относительная частота, %
ООО	`=СЧЁТЕСЛИ(Контрагенты!I2:I101;"ООО")`	`=B2/СУММ($B$2:$B$4)`	`=C2*100`
АО	`=СЧЁТЕСЛИ(Контрагенты!I2:I101;"АО")`	`=B3/СУММ($B$2:$B$4)`	`=C3*100`
ИП	`=СЧЁТЕСЛИ(Контрагенты!I2:I101;"ИП")`	`=B4/СУММ($B$2:$B$4)`	`=C4*100`
Итого	`=СУММ(B2:B4)`	`=СУММ(C2:C4)`	`=СУММ(D2:D4)`

Шаг 3. Проверьте: сумма относительных частот = 1, сумма процентов = 100%.

Шаг 4. Постройте полигон частот:

1. Выделите столбцы «Форма собственности» и «Частота» (A1:B4).
2. Вкладка «Вставка» → «Диаграммы» → «Гистограмма» (столбчатая).
3. Назовите диаграмму «Распределение контрагентов по форме собственности».
4. Подпишите оси: X — «Форма собственности», Y — «Частота».
5. При необходимости добавьте подписи данных (правый клик по столбцу → «Добавить подписи данных»).

Шаг 5. При желании добавьте линию тренда (полиномиальную), чтобы показать огибающую. Но для номинального признака это не обязательно — достаточно столбцов.

Результат: таблица частот, гистограмма и полигон частот.

Задание 1.4. Делаем выводы

Шаг 1. Создайте новый лист «Выводы».

Шаг 2. Напишите 5–7 предложений по шаблону:

«По результатам разведывательного анализа данных 100 контрагентов выявлено:
– ___ контрагентов с признаками фирм-однодневок (выручка > 100 млн при штате 1 человек);
– ___ контрагентов с пропусками в контактных данных;
– ___ контрагентов с аномально низким уставным капиталом;
– ___ дубликатов ИНН.
Распределение по формам собственности: ООО – ___%, АО – ___%, ИП – ___%.
Наибольший риск представляют контрагенты ___, так как ___.
Рекомендуется: ___».

Шаг 3. В рекомендациях используйте управленческие решения:

- запросить дополнительные документы;
- провести выездную проверку;
- исключить из списка поставщиков;
- передать информацию в службу финансового мониторинга;
- установить повышенный контроль расчётов.

Пример вывода:

«По результатам разведывательного анализа 100 контрагентов выявлено: 4 контрагента с признаками фирм-однодневок (выручка > 100 млн при штате 1 человек); 6 контрагентов с пропусками в контактных данных; 3 контрагента с аномально низким уставным капиталом; 1 дубликат ИНН. Распределение по формам собственности: ООО – 72%, АО – 18%, ИП – 10%. Наибольший риск представляют контрагенты с высокой выручкой при минимальном штате, так как это классический признак транзитных фирм. Рекомендуется: запросить у этих контрагентов пояснения по хозяйственным операциям, проверить их по базе ФНС и при отсутствии подтверждений – исключить из списка поставщиков».

ЧАСТЫЕ ОШИБКИ

1. **Неверный диапазон в формулах.** Если данные заканчиваются на строке 101, диапазон должен быть A2:A101, а не A1:A100.
2. **Разделители.** В русской версии Excel аргументы разделяются точкой с запятой (;), а не запятой.
3. **Забыли про метки.** Если в сводной таблице не поставить галочку «Метки в первой строке», Excel воспримет заголовок как данные.
4. **Сортировка без возврата.** Если отсортировали столбец, не забудьте вернуть исходный порядок или используйте отдельный столбец с нумерацией.

ВОПРОСЫ ДЛЯ ЗАЧЁТА ПО ТЕМЕ

1. Чем количественные данные отличаются от качественных? Приведите примеры из таблицы контрагентов.
2. Что такое дискретные и непрерывные данные? К какому типу относится численность сотрудников?
3. Почему для номинальных данных нельзя считать среднее?
4. Что такое относительная частота? Чему равна сумма всех относительных частот?
5. Что показывает полигон частот?
6. Какие виды аномалий вы знаете? Приведите примеры из работы.
7. Почему сочетание «выручка > 100 млн при штате 1 человек» считается «красным флагом»?
8. Какие функции Excel использовались для сводки? Что делает каждая из них?
9. Чем `СЧЁТЗ` отличается от `СЧИТАТЬПУСТОТЫ`?
10. Как построить сводную таблицу по форме собственности?
11. Как связаны тип данных и метод анализа?