# ЛАБОРАТОРНАЯ РАБОТА №5. ВЫБОРОЧНОЕ НАБЛЮДЕНИЕ

**Цель:** Научиться формировать выборку, рассчитывать ошибки выборки, определять необходимый объём и распространять результаты на генеральную совокупность. Дополнительно — закрепить навыки работы с логическими функциями и сводными таблицами.

---

## ВВЕДЕНИЕ

На лекции мы разобрали главный принцип выборочного наблюдения: **проверить всё невозможно, но можно проверить правильную часть.** Мы выяснили, что:

1. Выборка должна быть **репрезентативной** — то есть мини-копией генеральной совокупности.
2. Ошибка выборки **неизбежна,** но её можно рассчитать и контролировать.
3. Существует формула для определения **необходимого объёма выборки** — чтобы не тратить ресурсы впустую.
4. Результаты выборки можно **распространить** на всю совокупность с заданной вероятностью.

Теперь применим эти знания на практике. У вас есть 500 счетов-фактур. Ваша задача как аналитика проверить не все 500, а **правильно отобранные 50,** и на основе этой проверки сделать обоснованный вывод обо всей подборке счетов.

**Важно:** все расчёты выполняются в Excel. Результатом работы является файл Excel с расчётами и отчёт с выводами.

---

## ИСХОДНЫЕ ДАННЫЕ

**Файл-заготовка:** `lab5_invoices.xlsx`

Файл содержит 500 строк с данными о счетах-фактурах. Столбцы:

| Столбец | Описание |
|---|---|
| A | Номер счёта (от 1 до 500) |
| B | Дата |

| Столбец | Описание |
|---|---|
| C | Контрагент |
| D | Сумма счёта, руб. |
| E | Статус оплаты (Оплачен / Не оплачен / Частично) |
| F | Наличие нарушений (Да / Нет) |

**Генеральная совокупность:** N = 500 счетов.
**Признак для анализа:** сумма счёта (столбец D).
**Дополнительный признак:** наличие нарушений (столбец F).

---

# ЗАДАНИЕ 1. ФОРМИРОВАНИЕ ВЫБОРКИ (25 минут)

## Шаг 1. Рассчитайте параметры генеральной совокупности

В свободных ячейках (например, H2–H6) рассчитайте:

1. **Средняя сумма счёта по всей совокупности.**
2. **Дисперсия по всей совокупности.**
3. **Стандартное отклонение.**
4. **Минимум и максимум.**

В ячейку H1 добавьте заголовок **«Эталонные показатели»**, с ними вы будете сравнивать параметры выборки.

## Шаг 2. Сформируйте механическую выборку (каждый 10-й счёт)

Механическая выборка — это отбор каждой k-й единицы. При N = 500 и n = 50 шаг k = 500 / 50 = 10.

**Задача:** Отобрать каждый 10-й счёт (номера 10, 20, 30, ..., 500).

На новом листе (назовите его «Механическая») создайте таблицу:

| № | Номер счёта | Сумма |
|---|---|---|
| 1 | 10 | |
| 2 | 20 | |
| ... | ... | ... |
| 50 | 500 | |

Для заполнения сумм используйте функцию `ВПР()`:

```
text
=ВПР(B2; lab5_invoices!A:D; 4; ЛОЖЬ)
```

Где B2 — номер счёта, `lab5_invoices!A:D` — весь диапазон ваших данных, 4 — номер столбца с суммой, ЛОЖЬ — точное совпадение.

ВАЖНО!

**ВПР** (VLOOKUP) — это функция Excel для поиска значения в первом столбце таблицы и возврата соответствующего значения из указанного столбца справа. Синтаксис:

**ВПР(искомое_значение; таблица; номер_столбца; [интервальный_просмотр]).**

Искомое значение – что искать; таблица – диапазон, где искать; номер_столбца – откуда выводить результат. Последний аргумент задаёт тип совпадения: ЛОЖЬ (0) — точное, ИСТИНА (1) — приблизительное. Функция ищет только слева направо, поэтому искомый столбец всегда должен быть первым в диапазоне. Для поиска в обратном направлении или по нескольким условиям удобнее использовать ИНДЕКС+ПОИСКПОЗ или XLOOKUP.

Рассмотрим пример работы функции ВПР:

| | A | B | C | D | E | F |
|---|---|---|---|---|---|---|
| **1** | **Номер счёта (1)** | **Дата (2)** | **Контрагент (3)** | **Сумма счёта (4)** | **Статус оплаты( 5)** | **Наличие нарушений (6)** |
| **2** | 1 | 17.01.2024 | ООО «Ромашка» | 84900 | Оплачен | Нет |
| **3** | 2 | 13.01.2024 | АО «Вектор» | 30700 | Оплачен | Нет |
| **4** | 3 | 14.08.2024 | ИП Иванов И.И. | 12200 | Оплачен | Нет |
| **5** | 4 | 07.12.2024 | ООО «Север» | 110600 | Оплачен | Нет |
| **6** | 5 | 04.09.2024 | ООО «Заря» | 8200 | Оплачен | Нет |

По данной таблице (диапазон **A1:F6**) найти автоматически сумму счета (столбец № 4 нашей таблицы) с номером 2:

=ВПР(2; **A1:F6**; 4; ЛОЖЬ)

## Шаг 3. Сформируйте случайную выборку (50 счетов)

Случайная выборка — это отбор, при котором каждая единица имеет равный шанс попасть в выборку.

**Задача:** Сгенерировать 50 случайных номеров от 1 до 500.

На новом листе (назовите его «Случайная») создайте таблицу:

| № | Случайный номер | Сумма |
|---|---|---|
| 1 | =СЛУЧМЕЖДУ(1;500) | |
| 2 | =СЛУЧМЕЖДУ(1;500) | |
| ... | ... | ... |
| 50 | =СЛУЧМЕЖДУ(1;500) | |

**Важно:** функция `СЛУЧМЕЖДУ()` пересчитывается при каждом изменении файла. Чтобы зафиксировать значения, скопируйте столбец со случайными номерами и вставьте его как «Значения» (Специальная вставка → Значения).

Затем заполните суммы через `ВПР()` так же, как в механической выборке.

## Шаг 4. Сравните выборки с генеральной совокупностью

Показатели генеральной совокупности были рассчитаны на шаге 1. Для подсчета значений по выборкам используйте функции дисперсии и стандартного отклонения, предназначенные **для выборок** (они имеют суффикс «.В»)!

Оформите таблицу:

| Показатель | Генеральная | Механическая | Случайная |
|---|---|---|---|
| Средняя сумма | | | |
| Дисперсия | | | |
| Стандартное отклонение | | | |
| Минимум | | | |

| Показатель | Генеральная | Механическая | Случайная |
|---|---|---|---|
| Максимум | | | |

### Шаг 5. Ответьте на вопросы в выводе

1. Насколько средняя в механической выборке отличается от генеральной?
2. Насколько средняя в случайной выборке отличается от генеральной?
3. Какая выборка ближе к генеральной? Почему?
4. Может ли случайная выборка случайно оказаться «плохой»? Что с этим делать?

**Подсказка для вывода:** обе выборки дают приблизительную оценку. Разница между выборочной и генеральной средней — это **ошибка выборки.** Мы её рассчитаем в следующем задании.

---

## ЗАДАНИЕ 2. РАСЧЁТ ОШИБКИ ВЫБОРКИ

### Шаг 1. Возьмите случайную выборку из Задания 1

Будем работать с ней. Если случайная выборка оказалась слишком далёкой от генеральной, это нормально — мы сейчас рассчитаем, насколько она может отклоняться.

### Шаг 2. Рассчитайте среднюю ошибку выборки

Для **бесповторного** отбора (мы не возвращаем счёт обратно в совокупность):

$$\mu = \sqrt{\frac{\sigma^2}{n} \cdot \left(1 - \frac{n}{N}\right)}$$

Где:

- σ² — дисперсия в выборке (найдена на шаге 4 задания 1);
- n = 50 — объём выборки;
- N = 500 — объём генеральной совокупности.

**Для расчета квадратного корня в Excel используйте формулу КОРЕНЬ(значение).**

Запишите результат: μ.

## Шаг 3. Рассчитайте предельную ошибку

При коэффициенте доверия t = 2 (вероятность 95,4%) предельная ошибка составит:

$$\Delta = t \cdot \mu = 2 \cdot \mu$$

Запишите результат в ячейку: Δ = .

## Шаг 4. Постройте доверительный интервал

$$\tilde{X} - \Delta \leq \overline{X} \leq \tilde{X} + \Delta$$

где $\tilde{X}$ – среднее значение по выборке, $\overline{X}$ – среднее значение по генеральной совокупности.

Оформите таблицу:

| Показатель | Значение |
|---|---|
| Средняя в выборке | |
| Средняя ошибка (μ) | |
| Предельная ошибка (Δ) | |
| Нижняя граница интервала | |
| Верхняя граница интервала | |

## Шаг 5. Ответьте на вопросы в выводе

1. В каких пределах с вероятностью 95,4% лежит истинная средняя сумма счёта?
2. Попадает ли генеральная средняя (из Задания 1) в этот интервал?
3. Если генеральная средняя **не попала** в интервал — что это означает? (Возможные причины: выборка оказалась неудачной, есть систематическая ошибка, данные содержат аномалии.)

---

# ЗАДАНИЕ 3. ОПРЕДЕЛЕНИЕ НЕОБХОДИМОГО ОБЪЁМА ВЫБОРКИ

## Шаг 1. Постановка задачи

Требуется, чтобы предельная ошибка выборки не превышала **Δ = 100 руб.** при вероятности 95,4% (коэффициент доверия t = 2). Дисперсия из пилотного исследования = 25 000.

**Вопрос:** Сколько счетов нужно проверить?

## Шаг 2. Рассчитайте необходимый объём выборки

Для **бесповторного** отбора:

$$n = \frac{\sigma^2 t^2 N}{\Delta^2 \cdot N + \sigma^2 t^2}$$

Где:

- N = 500 — объём генеральной совокупности;
- t = 2 — коэффициент доверия;
- σ² = 25 000 — дисперсия, руб²;
- Δ = 1000 — допустимая предельная ошибка, руб.

Запишите результат в ячейку n =

Округлите **вверх** до целого числа с помощью функции `ОКРУГЛВВЕРХ()`(нельзя проверить 39,8 счёта).

## Шаг 3. Сравните с текущей выборкой

| Показатель | Значение |
|---|---|
| Текущий объём выборки (n) | 50 |
| Необходимый объём выборки при Δ = 1000 | |
| Необходимый объём выборки при Δ = 5000 | |
| Разница при Δ = 1000 | |

| Показатель | Значение |
|---|---|
| Разница при Δ = 5000 | |

### Шаг 4. Ответьте на вопросы в выводе

1. Достаточно ли 50 счетов для заданной точности?
2. Если необходимый объём **больше** 50 — что нужно сделать?
3. Если необходимый объём **меньше** 50 — можно ли сократить проверку? Какие риски?

---

## ЗАДАНИЕ 4. Риск - анализ

### Шаг 1. Постановка задачи

Необходимо классифицировать счета из случайной выборки по уровню риска. Используйте функцию `ЕСЛИ()`.

### Шаг 2. Добавьте столбец «Уровень риска»

В случайной выборке (лист «Случайная») добавьте новый столбец E «Уровень риска».

**Логика классификации нам уже знакома по лабораторным в Python:**

- Если сумма счёта > 100 000 руб. **И** есть нарушения → «Высокий риск»
- Если (сумма счёта > 100 000 руб. **И** нет нарушений) **ИЛИ** (сумма счёта ≤ 100 000 руб. **И** есть нарушения) → «Средний риск»
- Если сумма счёта ≤ 100 000 руб. **И** нет нарушений → «Низкий риск»

### Шаг 3. Запишите формулу

Используя функции `И()`, `ИЛИ()` и `ЕСЛИ()`, постройте формулу, соответствующую описанной логике классификации.

ВАЖНО! Справка по функциям:

**И** — логическая функция, возвращает ИСТИНА, только если все аргументы истинны. Синтаксис: **И(логическое условие1; [логическое условие 2]; ...)**.

**ИЛИ** — логическая функция, возвращает ИСТИНА, если хотя бы один аргумент истинен. Синтаксис: **ИЛИ(логическое условие1; [логическое условие2]; ...)**.

**ЕСЛИ** — функция проверки условия: возвращает одно значение, если условие истинно, и другое, если ложно. Синтаксис: **ЕСЛИ(условие; значение_если_истина; [значение_если_ложь])**.

**Обратите внимание**: внутри функций для разделения условий используется знак «;».

### Шаг 4. Подсчитайте количество по категориям

Для подсчета счетов в каждом уровне риска используйте уже известную функцию =СЧЕТЕСЛИ(). Доля рассчитывается стандартным отношением, не забудьте перевести в % любым известным способом.

Оформите таблицу:

| Уровень риска | Количество | Доля, % |
|---|---|---|
| Высокий | | |
| Средний | | |
| Низкий | | |
| **Итого** | 50 | 100 |

### Шаг 5. Ответьте на вопросы в выводе

1. Какая доля счетов в выборке относится к высокому риску?
2. Можно ли распространить эту долю на всю совокупность (500 счетов)? Сколько счетов высокого риска ожидается?
3. Что вы порекомендуете службе безопасности?

---

## ЗАДАНИЕ 5. Исследуем связь статуса оплаты и наличия нарушений

### Шаг 1. Постановка задачи

Нужно построить сводную таблицу, которая покажет структуру счетов по двум признакам: **статус оплаты** (столбец E) и **наличие нарушений** (столбец F).

## Шаг 2. Постройте сводную таблицу

**Инструмент Excel:** Вставка → Сводная таблица.

**Настройки:**

- **Строки:** Статус оплаты (Оплачен / Не оплачен / Частично).
- **Столбцы:** Наличие нарушений (Да / Нет).
- **Значения:** Количество счётов (или сумма счётов).

## Шаг 3. Оформите результат

| Статус оплаты | Нарушения: Да | Нарушения: Нет | Всего |
|---|---|---|---|
| Оплачен | | | |
| Не оплачен | | | |
| Частично | | | |
| **Итого** | | | |

## Шаг 4. Оценка тесноты связи признаков «статус оплаты» и «нарушения»

В случае, когда каждый из качественных признаков состоит более чем из двух групп, то для определения тесноты связи возможно применение коэффициентов взаимной сопряженности Пирсона и Чупрова.

**Коэффициенты Пирсона** ($K_П$) **и Чупрова** ($K_Ч$) – это показатели взаимной сопряжённости (связи) двух категориальных (не количественных) признаков. Они применяется для анализа таблиц сопряжённости, когда нужно оценить, насколько сильно значения одного признака связаны со значениями другого.

Один из подходов к расчету этих коэффициентов основан на использовании $\chi^2$- критерия Пирсона (читается «хи – квадрат»):

$$\chi^2 = n \cdot \left( \sum \frac{x_{ij}^2}{x_i \cdot x_j} - 1 \right)$$

где $x_i$ – сумма показателей по строке $i$;

$x_j$ - сумма показателей по столбцу $j$;

$x_{ij}$ - показатель, находящийся на пересечении $i$-ой строки и $j$ – столбца.

$n$ - число наблюдений (объем выборки).

Разберем расчет хи-квадрат критерия на примере следующей сводной таблицы:

| **Количество по полю Номер счета** | **Названия столбцов** | | |
|---|---|---|---|
| **Названия строк** | **Да** | **Нет** | **Общий итог** |
| Не оплачен | 51 | 40 | 91 |
| Оплачен | 39 | 295 | 334 |
| Частично | 10 | 65 | 75 |
| **Общий итог** | **100** | **400** | **500** |

Выполним промежуточные вычисления $\frac{x_{ij}^2}{x_i \cdot x_j}$

| **Количество по полю Номер счета** | **Названия столбцов** | | |
|---|---|---|---|
| **Названия строк** | **Да** | **Нет** | |
| Не оплачен | =51$^2$/(100*91) | =40$^2$/(400*91) | |
| Оплачен | =39$^2$/(100*350) | =295$^2$/(400*350) | |
| Частично | =10$^2$/(100*75) | =65$^2$/(400*75) | |
| **Сумма** | **=СУММ1** | **=СУММ2** | **=СУММ1 + СУММ2** |

$$\chi^2 = n \cdot \left(\sum \frac{x_{ij}^2}{x_i \cdot x_j} - 1\right) = 500 \cdot (\text{СУММ1} + \text{СУММ2} - 1).$$

Найдя хи-квадрат по нашим данным, перейдем к непосредственному вычислению коэффициентов сопряженности:

$$K_{\text{П}} = \sqrt{\frac{\chi^2}{n+\chi^2}} - \text{коэффициент Пирсона}$$

$$K_{\text{Ч}} = \sqrt{\frac{\chi^2}{n \cdot \sqrt{(k_1-1)\cdot(k_2-1)}}} - \text{коэффициент Чупрова}$$

$k_1$ - число строк в таблице сопряженности (число статусов оплаты);

$k_2$ - число столбцов в таблице сопряженности (число градаций признака «Наличие нарушений»;

Оценим силу связи между **статусом оплаты счёта** и **наличием нарушений** с помощью коэффициентов Пирсона и Чупрова:

- если оба коэффициента $\geq 0.3$, то связь имеется;
- чем ближе значения коэффициентов к 1, тем теснее связь;
- если оба коэффициента $\leq 0.3$, то связь отсутствует;
- если $К_П > 0,3$, а $К_Ч < 0,3$, то **ориентируемся на значение коэффициента Чупрова,** так как он учитывает размерность таблицы и более точен.

## Шаг 5. Ответьте на вопросы в выводе

1. Какая категория в сводной таблице самая многочисленная?
2. Есть ли связь между статусом оплаты и наличием нарушений согласно коэффициентов Пирсона и Чупрова? (Например, все неоплаченные счета – с нарушениями?)

# ЗАДАНИЕ 6. ВЫВОД

Напишите итоговый вывод по всей работе (7–10 предложений) по следующему шаблону:

«По результатам выборочной проверки 50 счетов из 500 средняя сумма счёта составила ___ руб. С вероятностью 95,4% истинная средняя лежит в интервале от ___ до ___ руб. Предельная ошибка выборки составила ___ руб., что составляет ___% от средней.

Для достижения точности Δ = 100 руб. необходимо проверить ___ счетов (больше/меньше текущих 50).

Классификация по уровню риска показала: ___% счетов относятся к высокому риску, ___% – к среднему, ___% – к низкому. Если распространить эти доли на всю совокупность, ожидается ___ счетов высокого риска.

Сводная таблица выявила самую многочисленную категорию счетов ____. Согласно значений коэффициентов сопряженности Чупрова и Пирсона связь между статусом оплаты и наличием нарушений: ___.

Рекомендуется: ___».

**Критерий хорошего вывода:** он должен содержать конкретные цифры из ваших расчётов и чёткие рекомендации для службы безопасности.